

Παραγωγή Προσώπων Anime με Generative AI

VAE
Variational Autoencoder

VS

DCGAN
Deep Convolutional GAN

Dataset: Anime Face Dataset — 63.565 εικόνες **Framework:** PyTorch 2.1 **GPU:** T4 (Google Colab)

Το Πρόβλημα

Αυτόματη παραγωγή **συνθετικών εικόνων anime**
64×64 px από μηδενική βάση, σε
περιβάλλον περιορισμένων πόρων.

Γιατί έχει σημασία

Generative AI = κορυφαίος κλάδος DL.
Εφαρμογές: gaming, animation,
synthetic data augmentation.

Στόχοι Εργασίας

1

Εκπαίδευση VAE & DCGAN

από μηδέν, στο ίδιο dataset

2

Ποιοτική σύγκριση

οπτικά δείγματα, sharpness, diversity

3

Ποσοτική αξιολόγηση

με μετρική FID (Fréchet Inception Distance)

4

Ανάλυση latent space

παρεμβολές, δομή αναπαράστασης

63.565

Εικόνες
(Kaggle)

20.000

Χρησιμοποιήθηκαν
(18K train / 2K val)

64×64

Ανάλυση
(μετά resize)

18k / 2k

Train /Val split

Pipeline Προεπεξεργασίας

1

Φόρτωση

ImageFolder
(Kaggle)

2

CenterCrop

→ 64×64 px

3

Normalize

[-1, 1]

4

DataLoader

batch=128
pin_memory

5

Reproducibility

seed=42
(torch+numpy)

EDA Ευρήματα:


Μέση ανάλυση 88×88 px (εύρος 28–180 px) • Μέσες τιμές RGB: 0.694 / 0.593 / 0.572 • Κανονικές κατανομές χρωμάτων ανά κανάλι — ομοιόμορφο dataset χωρίς σημαντικό bias

Δείγμα Εικόνων — Anime Face Dataset




Δείγμα εικόνων — Anime Face Dataset

Κατανομή Τιμών Pixel ανά Κανάλι (RGB)



Κατανομή τιμών pixel ανά κανάλι RGB

Μέση Εικόνα Dataset (n=1000)



Τυχαία Εικόνα



Μέση εικόνα dataset & τυχαίο δείγμα

VAE — 11.8M παράμετροι

Encoder:	4× Conv2d: 3→64→128→256→512 stride=2, LeakyReLU + BatchNorm
Latent:	dim=256 → μ, σ → reparameterize
Decoder:	4× ConvTranspose2d: 512→256→128→64→3 ReLU + BatchNorm, Tanh output
Loss:	β -VAE: Recon(MSE) + $\beta \times \text{KLD}$ ($\beta=1.5$)
Optimizer:	Adam LR=1e-3 + ReduceLROnPlateau
Epochs:	30

DCGAN — 6.34M παράμετροι

Generator:	NZ=100→512→256→128→64→3 ConvTranspose2d + BN + ReLU, Tanh
Discriminator:	3→64→128→256→512→1 Conv2d + BN + LeakyReLU, Sigmoid
Stability:	Label smoothing (real=0.9, fake=0.0) Instance noise $\sigma=0.05$
Weights:	Αρχικοποίηση $N(0, 0.02)$
Optimizer:	Adam LR=2e-4, $\beta_1=0.5$ (G & D)
Epochs:	50

VAE

Epoch	Train Loss	KLD
1	179.924*	118.596
10	481	6.54
20	342	5.34
30	290	5.02


* KL Collapse epoch 1 — τυπικό φαινόμενο χωρίς warmup

DCGAN

Epoch	Loss_G	D(G(z))
1	8.06	0.0056
25	4.01	0.0322
50	2.95	0.0750

$D(G(z))$ 0.006→0.075: ο Generator βελτιώνεται αλλά δεν ξεπερνά τον Discriminator

Καμπύλες Εκπαίδευσης — VAE & DCGAN




Σχ. 1: VAE — Train/Val Loss & Recon/KLD ανάλυση (30 epochs) | DCGAN — G/D Loss & $D(x)/D(G(z))$ (50 epochs)

Σύγκριση: Real vs VAE vs DCGAN


□ Πραγματικές Εικόνες



□ VAE — Ανακατασκευή



□ VAE — Παραγόμενες



□ DCGAN — Παραγόμενες



Real

63.565 εικόνες, ανάλυση $88 \times 88 \rightarrow 64 \times 64$. Ευκρινείς, ποικίλα χαρακτηριστικά.

VAE Recon

Διατηρεί δομή & χρώματα. Εμφανής blurriness λόγω MSE pixel-wise loss.

VAE Gen

Θολές εικόνες από random sampling $N(0, I)$. Εκτός κύριου manifold.

DCGAN Gen

Ευκρινείς λεπτομέρειες, ρεαλιστική υφή. Adversarial loss = sharp images.

FID Score (Fréchet Inception Distance) —
χαμηλότερο = καλύτερο

52.5% βελτίωση FID

VAE

244.72

FID Score

30 epochs • 11.8M params

ΝΙΚΗΤΗΣ

DCGAN

116.16

FID Score

50 epochs • 6.34M params

Μετρική	VAE	DCGAN
FID Score (↓)	244.72	116.16 ✓
Παράμετροι	11.815.427	6.342.272
Latent Dim	256 (μ, σ)	100 (noise z)
Sharpness	Θολές εικόνες	Ευκρινείς εικόνες ✓
Interpolation	Ομαλή ✓	Μη τετριμμένη
Εκπαίδευση	Σταθερή ✓	Ευαίσθητη (G/D balance)

VAE — Ανακατασκευή

- Διατηρεί γενική δομή
- Χρώμα μαλλιών, θέση ματιών
- Blurriness λόγω MSE loss
- Pixel-wise averaging

VAE — Παραγωγή

- Ακόμα πιο θολές εικόνες
- Δειγματοληψία από $N(0, I)$
- Εκτός κύριου manifold
- Αλλά: δομημένο latent space

DCGAN — Παραγωγή

- Ευκρινείς λεπτομέρειες ✓
- Ρεαλιστικές υφές ✓
- Αναγνωρίσιμα anime χαρακτ. ✓
- Adversarial → sharp edges ✓

Γιατί κέρδισε το DCGAN;

A

Adversarial Loss

Ο Discriminator = learnable perceptual loss
→ εξαναγκάζει τον Generator να παράγει
εικόνες αδιάκριτες από πραγματικές

B

Sharp Features

Αντί για MSE (pixel-wise average → blur),
το DCGAN μαθαίνει υψηλής συχνότητας
λεπτομέρειες

C

Παράμετροι

Λιγότερες παράμετροι (6.34M vs 11.8M)
αλλά πιο αποτελεσματική αρχιτεκτονική

Περιορισμοί & Δυσκολίες

KL Collapse:

$KLD=118.596$ στην epoch 1 — χωρίς KL warmup το VAE αρχικά
αποτυγχάνει. Πέφτει φυσικά από epoch 2.

DCGAN Imbalance:

$D(x) \approx 0.75 \gg 0.5$ όλη την εκπαίδευση. Ο Discriminator κυριαρχεί — G
δεν ξεγελά αποτελεσματικά.

Dataset Υποχρήση:

20.000 / 63.565 εικόνες. Με το πλήρες dataset, αμφότερα τα μοντέλα
θα βελτιώνονταν.

FID Αξιοπιστία:

FID υπολογίστηκε με 2.000 εικόνες — υψηλή διασπορά. Απαιτούνται
50.000+ για αξιόπιστα αποτελέσματα.

DCGAN

1

Νικητής — ποιότητα εικόνας

Adversarial training → sharp, ρεαλιστικά anime. Κατάλληλο για visual fidelity.

FID 116.16

VAE

2

Σταθερό — controllable

Δομημένο latent space, ομαλές παρεμβολές. Κατάλληλο για latent exploration.

FID 244.72

Μελλοντικές Βελτιώσεις:

Πλήρες dataset (63.565 εικόνες) • Περισσότερες εποχές • KL warmup για VAE • Progressive growing για DCGAN • StyleGAN2 / Diffusion Models

Ευχαριστώ για την Προσοχή σας!

Ερωτήσεις;

Σύνοψη

DCGAN FID=116.16 vs VAE FID=244.72 → **52.5% βελτίωση**

Dataset: Anime Face (Kaggle) • PyTorch 2.1 • Google Colab T4 GPU

VAE: σταθερή εκπαίδευση + latent interpolation • DCGAN: sharp εικόνες + adversarial ποιότητα

Βιβλιογραφία:

[1] Kingma & Welling (2013) — VAE • [2] Goodfellow et al. (2014) — GANs • [3] Radford et al. (2015) — DCGAN • [4] Heusel et al. (2017) — FID • [5] Higgins et al. (2017) — β -VAE